



Nom : Auvray – Boucneau - Warlop

Prénom : Clément - Gabriel - Laure

Classe : A3

Module : Projet Analyse de données & Cycle – Big Data

Responsable du module : Abir El Haj

Titre du document : Rapport du projet big data

Date et heure d'envoi : lundi 16 juin 2025 à 12h

Nombre de mots : 2229

- ✓ En adressant ce document à l'enseignant, je certifie que ce travail est le mien et que j'ai pris connaissance des règles relatives au référencement et au plagiat

Sommaire

Introduction.....	3
I- Exploration des données.....	3
A- Description du jeu de données.....	3
B- Statistiques descriptives univariées.....	4
C- Nettoyage des données.....	4
i- Valeurs manquantes, valeurs aberrantes	4
ii- Doublons.....	5
II- Visualisation des données sur des graphiques.....	5
III- Visualisation des données sur une carte	7
Construire des trajectoires de bateaux	7
IV- Fonctionnalités subsidiaires	8
A - Pour les bateaux de type cargo	8
B - Types de bateaux ayant des informations liées au chargement et les routes et ports différents des cargos	8
V- Étude des corrélations.....	9
A- Analyses des liens entre les variables.....	9
B- Analyses bivariées	10
C- Etude des relations entre variables qualitatives.....	10
VI- Prédiction de la variable « VesselType».....	12
A- Régression Linéaire.....	12
B- Régression logistique	12
Conclusion	13

Introduction

Le projet initial est de concevoir et développer une application d'étude des données AIS concernant les bateaux dans le golfe du Mexique. Pour la partie Big Data, les objectifs sont variés. Dans un premier temps, nous parlerons de l'extraction des données, ensuite, nous ferons une visualisation des données et un nettoyage pour pouvoir les utiliser correctement. Pour finir, nous réaliserons une analyse de données en utilisant des modèles statistiques comme une régression linéaire et l'étude des corrélations entre les caractéristiques.

Pour réaliser ce projet, nous avons utilisé le langage de programmation R développé pour des applications statistiques et très répandu dans le domaine de la science de données.

I- Exploration des données

A- Description du jeu de données

Le jeu de données que nous analysons, provient du fichier *vessel-total-clean.csv*. Les données proviennent du système d'identification automatique (AIS) des navires circulant dans le golfe du Mexique. Ce fichier est composé de valeurs qualitatives et quantitatives. Les valeurs quantitatives correspondent aux valeurs numériques, des valeurs que l'on peut compter alors que les valeurs qualitatives ne sont pas mesurables.

Les valeurs quantitatives sont :

- LON : Longitude du bateau
- LAT : Latitude du bateau
- SOG (*Speed Over Ground*) : Vitesse de déplacement sur le fond marin
- COG (*Course Over Ground*) : Direction réelle du déplacement
- *Heading* : Direction théorique (non réelle)
- *Length* : Longueur du bateau (en mètres)
- *Width* : Largeur du bateau (en mètres)
- *Draft* : Tirant d'eau, partie immergée du bateau (en mètres)

Les valeurs qualitatives sont :

- Id : Identifiant unique du bateau
- MMSI (*Maritime Mobile Service Identity*) : Identifiant radio maritime
- *BaseDateTime* : Date et heure de l'enregistrement
- *VesselName* : Nom du bateau
- IMO : Numéro d'immatriculation international.
- *CallSign* : Indicatif radio du bateau

- *VesselType* : Type de bateau (cargo, tanker, fishing vessel, etc.)
- *Status* : État du bateau (en mouvement, à l'ancre, etc.)
- *Cargo* : Informations sur le chargement
- *TransceiverClass* : Type d'émetteur-récepteur utilisé

B- Statistiques descriptives univariées

L'objectif de l'analyse univariée est de comprendre la distribution de chaque variable quantitative indépendamment des autres. Pour cela, nous avons calculé plusieurs indicateurs statistiques pour chaque variable comme :

- La moyenne : elle donne une idée de la valeur centrale globale des données
- La médiane : elle indique la valeur centrale plus robuste, notamment en cas de présence de valeurs extrêmes
- Les quartiles (Q1 – Q3) : ils délimitent les bornes de l'intervalle interquartile, contenant 50 % des valeurs centrales
- Les minimum et maximum : ils permettent de cerner l'amplitude des valeurs observées

C- Nettoyage des données

Pour nettoyer les données, nous avons identifié les valeurs manquantes, aberrantes et les doublons pour pouvoir ensuite soit les supprimer, soit les remplacer par la médiane.

i- Valeurs manquantes, valeurs aberrantes

Pour les valeurs manquantes, ce sont des “\n” dans le fichier csv, ce qui est facile à repérer. Nous les avons alors remplacés par des NA pour ensuite pouvoir les traiter. En tout, nous avons 326040 valeurs manquantes.

Pour chaque colonne, nous avons étudié la proportion des valeurs manquantes pour savoir si elles sont significatives ou non et nous avons décidé de les supprimer si c'était inférieur à 5%. Cependant, si le pourcentage est supérieur à 5%, elles sont significatives. Nous avons donc remplacé les NA par la médiane pour les quantitatives. Pour les qualitatives, nous avons remplacé par la mention “inconnu”.

Après cela, nous passons de 420217 lignes à 397503 lignes.

Pour les valeurs aberrantes, nous avons dû séparer les valeurs numériques des valeurs qualitatives. Pour les numériques, nous avons calculé le premier et troisième quartile pour pouvoir trouver un intervalle pour déterminer les valeurs aberrantes. Si la proportion des valeurs aberrantes représente moins de 3% de la colonne, alors on les

supprime, sinon on remplace aussi par la moyenne. Au final, moins de 6% des données sont perdues.

ii- Doublons


Nous avons calculé les doublons pour pouvoir les supprimer s'ils existent, mais nous n'en avons aucun.

II- Visualisation des données sur des graphiques

Pour cette partie, nous avons réalisé plusieurs types de graphiques :

Répartition des statuts des navires :


Répartition des statuts des navires



Répartition par type de bateau :

Répartition des bateaux par type


Nombre unique de bateaux : 141




Ce graphique circulaire présente la répartition des statuts des navires. On constate que la majorité des navires (59,1 %) sont en statut 0, associé à un état "en navigation". Les statuts 1 et 5, représentant des navires à l'arrêt ou amarrés, constituent chacun autour de 11 à 12 % du total.

Quant à la répartition des types de bateaux, on remarque une répartition assez homogène entre les transporteurs de passagers (60 à 69), les cargos (70 à 79) et les pétroliers (80 à 89).

Vitesse des bateaux :







Cet histogramme permet de visualiser que la plupart du temps les bateaux sont à l'arrêt dans le golfe du Mexique

Directions :


COG :

Heading :



On observe que les navires se déplacent majoritairement vers le nord-ouest, reflétant un trafic intense en direction des ports texans et louisianais. En revanche, les caps sont plus dispersés, avec une prédominance vers l'est et l'ouest, illustrant des routes maritimes à deux sens typiques. L'écart entre COG et Heading suggère des effets de courants.

Longueur vs largeur :




À l'aide de ces graphiques, nous pouvons conclure qu'une corrélation entre la longueur et la largeur des bateaux existe. L'erreur standard est visuellement faible.

III- Visualisation des données sur une carte

Construire des trajectoires de bateaux

Pour cette partie, nous avons utilisé *leaflet* pour réaliser une carte interactive qui nous permet d'afficher les différentes trajectoires des bateaux que l'on peut grouper par type, mais aussi visualiser la densité des trajectoires.



Sur cette carte, on peut voir les trajectoires des différents bateaux représentées par un trait. La couleur des traits représente les types de bateaux. Il est possible de sélectionner les bateaux par type, d'afficher les routes principales et les ports.

Les routes principales sont visualisées par la superposition de l'ensemble des trajectoires avec une faible opacité.

On aperçoit que les routes les plus empruntées sont :


- Houston – Miami
- Houston – Nouvelle-Orléans

- Miami – Nouvelle-Orléans

IV- Fonctionnalités subsidiaires


A - Pour les bateaux de type cargo

En cochant, cargos, seules les trajectoires des navires de type cargos seront affichées et la case “chargés” affiche les portions de trajectoires où les navires sont chargés. En cliquant sur leur trajet, on peut voir la modification du tirant d’eau et voir si le bateau est chargé.




B - Types de bateaux ayant des informations liées au chargement et les routes et ports différents des cargos

Les ports sont repérés par un *clustering* des lieux où s’arrêtent les navires. On remarque que certaines zones en mer se démarquent malgré un affinage du réglage de *dbscan*. Les couleurs représentent l’activité la plus présente dans la zone entre chargement, déchargement, arrêt simple.



V- Étude des corrélations

A- Analyses des liens entre les variables



Pour visualiser les liens potentiels entre les variables quantitatives, on a décidé de faire une matrice de corrélation entre les différentes variables. Ici, il s'agit d'une matrice de corrélation entre *VesselType*, *SOG*, *length*, *width*, *draft* et *cargo*. Il nous permet de bien visualiser le lien entre les différentes valeurs.


On peut voir ici que certains éléments influent plus sur *VesselType* que d'autres, comme *Length*, où le R^2 entre lui-même est *VesselType* est de 0.54. Malgré le

fait que *VesselType* et *Cargo* sont des variables qualitatives, après une analyse plus profonde des données, elle se comporte comme des variables quantitatives dans notre cas.

B- Analyses bivariées

La dernière image de la partie 2 met déjà en valeurs les relations entre les différentes variables en créant les nuages de points et en faisant une régression linéaire.

Cependant, si on veut étudier d'autres critères que la relation entre la longueur et le type de bateau, on peut utiliser les boîtes à moustaches. Voici 2 exemples qui ont une plus ou moins grande influence sur la variable *VesselType* :




C- Etude des relations entre variables qualitatives

Pour étudier les variables qualitatives, on a décidé de faire des tableaux croisés puis de faire des tests d'indépendance du χ^2 sur ses derniers.

On a donc réalisé un test du χ^2 entre les variables *VesselType* et *Cargo* grâce à la fonction `fisher.test()` avec le paramètre `simulate.p.value=TRUE` qui va nous permettre de prendre en charge un nombre plus important de ligne et est plus précise que `chisq.est()`. Cependant, il faut tout de même veiller à ne pas prendre un nombre de lignes trop grand, car la fonction possède ses limites. Dans notre cas, on a pris 30 000 lignes, ce qui devrait être suffisant pour analyser l'indépendance entre les variables.

Lorsqu'on exécute le test sur les variables *Cargo* et le type de bateau., on obtient un score de 0.0004998, ce qui veut dire que les 2 variables ont un lien statistique significatif.

Ci-dessous, vous trouverez un mosaicplot qui représente les occurrences des *VesselType* (axe Y soit vertical) en fonction des types de *Cargo* (axe X soit horizontal). La taille des barres est proportionnelle au nombre d'occurrences d'une combinaison. La couleur n'a aucune importance et ne sert qu'à différencier les barres.



D- Etude des relations entre variables qualitatives et quantitatives

Pour cette analyse, nous avons effectué une ANOVA entre le type de bateau (*VesselType*) et la vitesse sur le fond (*SOG*), ce qui a donné une p-value de 0,0022. Cela indique qu'il existe une différence statistiquement significative de vitesse selon le type de bateau. Autrement dit, la vitesse varie en fonction du type de bateau.

VI- Prédiction de la variable « VesselType »

A- Régression Linéaire

On a effectué une régression linéaire simple pour prédire *Length* en fonction de *Width*. On obtient un R^2 de 0.8474 ce qui veut dire que 84.74% des valeurs de *Width* sont expliquées par *Length* et une erreur d'estimation standard de 36.16.

B- Régression logistique

Nous allons ensuite prédire le type de bateau (*VesselType*) le plus précisément possible. Pour cela, on va utiliser toutes les valeurs pertinentes en plus d'ajuster la base de données initial.

- Prétraitement :

Les données qui nous intéressent sont : *SOG*, *Length*, *Draft*, *Width*, *Cargo*, *TransceiverCase* et *Status*.

Dans le cadre notre régression, on a décidé de prendre la base de données de base et de remplacer toutes les valeurs NA (qui ont été remplacées par 0) par les médianes en fonction de *VesselType*.

Par exemple, dans le premier tableau, on va remplacer NA par la médiane de tout le groupe, ce qui n'est pas idéal si on veut prédire *VesselType* avec *Length*. Dans le deuxième tableau, la médiane est calculée en fonction du groupe. Donc la valeur de *length* (NA) pour le dernier élément sera remplacé par une valeur plus représentative de son groupe. Cela permet à notre régression logistique d'être bien plus précise.

VesselType :	Length :	Médiane :
60	12	21
60	13	
60	14	
70	28	
70	29	
70	30	
70	NA	

VesselType :	Length :	Médiane :
60	12	13
60	13	
60	14	
70	28	29
70	29	
70	30	
70	NA	

On peut voir grâce à cette matrice de confusion que notre régression est plutôt précise même si elle a du mal à prédire les types moins représentés dans le jeu de données. Au final, avec un *train/test-split* de 70%/30%, on obtient un score de 0.93.

pred	60	61	69	70	71	74	79	80	82	84	89
60	47832	227	36	691	0	0	3	0	0	0	0
61	49	31	0	0	0	0	0	0	0	0	0
69	0	0	1611	0	0	0	0	0	0	0	0
70	682	0	50	28894	26	0	55	1195	0	0	0
71	0	0	0	0	1922	0	0	0	0	0	0
74	0	0	0	0	0	706	0	0	0	0	0
79	0	0	0	0	0	0	1038	0	0	0	0
80	0	0	0	2435	0	0	534	26657	536	427	722
82	0	0	0	22	0	0	0	0	238	0	0
84	0	0	0	0	0	0	0	0	0	7	0
89	0	0	0	0	0	0	0	555	0	0	1341

Conclusion

Ce projet vise à concevoir une application d'analyse des données AIS d'un groupe de navire. Après avoir extrait et préparé les données, nous avons utilisé des techniques de visualisation et de modélisation statistique à l'aide du langage R.

La première étape a consisté en un nettoyage approfondi du jeu de données, comme la suppression des doublons, le remplacement des valeurs manquantes ainsi que le traitement des valeurs aberrantes grâce à des seuils fondés sur des quantiles.

Nous avons ensuite exploré les données grâce à une carte interactive et des graphiques de régression linéaire ou des boîtes à moustaches par exemple. Ces visualisations nous ont permis de mettre en évidence les liens entre les différentes variables. Des tests statistiques ont aussi été effectués comme le calcul du χ^2 entre certaines données et une corrélation de Pearson.

Nous avons aussi réalisé une régression logistique multinomiale afin de prédire la variable *VesselType* en fonction des autres variables.

Grâce à une séparation entre données d'apprentissage et de test, nous avons pu évaluer la robustesse de notre modèle dans le but d'éviter les biais de sur-apprentissage. Les résultats montrent que les caractéristiques techniques des navires permettent de prédire leur type avec une très bonne fiabilité.